Liquidez Factura: anticipo de facturas electrónicas para pymes, con agentes que preparan y personas que deciden

Decisión solicitada: aprobar un **piloto de 6 meses por COP 3.500 M** (escenario base) con cuatro compuertas Go/No-Go, para validar un producto de primer piso que abre la relación directa del banco con pymes sin competir con sus entidades aliadas.

1. Problema y segmento

La demanda potencial de crédito mipyme en Colombia es de COP 122,49 billones (13,8% del PIB) y el exceso de demanda sobre la oferta ronda 7,6% del PIB; sin embargo, solo 33,2% de las pymes solicitó crédito en 2021 y la barrera principal es la **autoexclusión** (BID / Banca de las Oportunidades, 2026). **Segmento de entrada:** pequeñas y medianas empresas formales, con 2 o más años, que facturan electrónicamente a crédito (30-120 días) a pagadores medianos y grandes (≈ 39.000 empresas, supuesto a validar). **Problema prioritario:** caja atrapada en cuentas por cobrar, con opciones opacas y respuestas lentas.

2. Producto, propuesta de valor y priorización

Producto inicial: anticipo (descuento) de facturas aceptadas en RADIAN, con recurso, anticipo de 80-90% por banda de riesgo, tasa de 1,55%-1,99% mensual (por debajo del techo prudencial de usura de 28,34% E.A.), costo total transparente y decisión humana en menos de 24 h. El mercado lo respalda: las facturas endosadas en RADIAN pasaron de COP 11,2 billones (2022) a COP 46,7 billones (2025) (DIAN). Es **autoliquidable, de plazo corto y con riesgo apoyado en el pagador**; los no elegibles se refieren a aliados.

Para la pyme	Para el banco
Oferta indicativa en minutos, sin papeles, con costo total y neto a recibir	Relación directa y datos propios de comportamiento
Explicación de por qué sí o por qué no, y alternativas	Riesgo corto y diversificado; base para crédito de capital de trabajo y confirming

Primero: anticipo con recurso, scorecard por reglas, aprobación 100% humana, web. **Después:** confirming con pagadores ancla, modelo con datos de finanzas abiertas (Decreto 368 de 2026), autonomía acotada en montos pequeños, canal WhatsApp.

3. Solución agéntica integrada: autonomía, límites y controles

Principio: **el LLM propone, la política dispone**. Elegibilidad, banda, cupo y tasa salen de reglas deterministas y versionadas; la IA generativa (equipo CrewAI de redactor + crítico) solo redacta la explicación al cliente y el resumen al analista, y todo texto pasa por un guardrail de salida. Si un sistema o el modelo falla, el caso va a una persona; nunca se inventa una oferta.

Agente	Informa / recomienda	Nunca	Transfiere a
Onboarding	Requisitos; registra los 3 consentimientos; verifica RUES	Consultar sin autorización	Asesor pyme
Cumplimiento	Retiene ante coincidencia en listas	Revelar la coincidencia (sin tipping-off)	Oficial de cumplimiento
Facturas y fraude	Filtra facturas RADIAN; detecta doble negociación	Endosar, acusar	Analista de fraude
Riesgo	Banda, cupo, anticipo y tasa dentro de política	Aprobar; superar el techo de tasa	Analista / comité (≥ COP 800 M)
Asesor y copiloto (IA gen.)	Costo total; resumen verificable del caso	Prometer, decidir, enlaces, PII	Asesor / analista

Controles: sin consentimiento no hay consultas; NIT y PII enmascarados antes del modelo; scorecard explicable (cada exclusión tiene razón); defensa ante prompt injection (normalización, patrones, canary); máquina de estados que impide que la IA apruebe; justificación obligatoria y doble firma para desembolsar; traza por paso y auditoría sin PII. **Evals como compuerta de CI:** 93,3% de ataques bloqueados (2 semánticos declarados y contenidos porque la IA no decide), 0% falsos positivos, 100% de exactitud en el journey y en las invariantes de gobierno.

4. Valor esperado e inversión (modelo trimestral a 3 años)

COP millones	Pesimista	Base	Optimista
Inversión inicial	4.500	3.500	3.000
Ingresos año 3	5.719	34.659	106.220
Contribución año 3	(5.255)	8.426	49.553
Beneficio acumulado 3 años, tras inversión	(20.055)	3.934	70.000
VPN 3 años @ 15%	(16.920)	1.124	49.801
Payback (meses de operación)	> 36	33	15
Clientes activos al cierre del año 3	313	1.236	3.069

El caso base exige solo 2,2% del volumen anual endosado en RADIAN en 2025. Lo que más mueve el VPN: tasa de descuento, costo de fondeo, saldo por cliente y conversión (±20% cambian el signo del VPN). **Lectura honesta del valor de IA:** a esta escala el ahorro en analistas (≈ COP 303 M en 3 años) no paga la plataforma de IA (≈ COP 1.090 M, mayormente fija; los tokens son marginales). El retorno de la IA está en **conversión y experiencia** (+5 pp atribuidos al agente, a validar con A/B) y en **control**.

5. Principales riesgos y mitigación

Riesgo	Mitigación
Spread insuficiente si sube el fondeo o baja el precio	Precio por banda; gate G3 con unit economics; fondeo multilateral
Ticket menor al esperado (COP 150 M por cliente)	Piloto con 50 pymes y 3 pagadores ancla; producto de menor ticket como plan B
Fricción en RADIAN (aceptación del pagador)	Priorizar pagadores que aceptan; confirming en fase 2
Conflicto de canal con entidades aliadas	Reglas de segmento y referidos; decisión D2 de junta
Riesgo de modelo y reputacional de la IA	La IA no decide; crítico + guardrail; evals en CI; muestreo humano semanal
Fraude (doble negociación) y SARLAFT	Verificación RADIAN y screening antes de cualquier oferta; personas responsables

6. Roadmap de 6 meses y decisiones que debe tomar el banco

Mes	Fase	Compuerta
1-2	Fundaciones: concepto jurídico, fondeo, contratos de datos, integraciones sandbox	G1: Go/No-Go técnico-regulatorio
2-3	MVP cerrado: PostgreSQL, SSO/RBAC, backtesting del scorecard, 10 pymes asistidas	G2: evals ≥ umbral, 0 aprobaciones sin humano
3-5	Piloto controlado: 50 pymes, 3 pagadores ancla, A/B con agente, observabilidad de costo	G3: conversión ≥ 30%, mora ≤ 3%, IA ≤ COP 2.000/caso
5-6	Preparar escala: Kubernetes, HPA, autonomía acotada si los datos lo permiten	G4: decisión de junta para escalar

Decisiones previas a escalar: D1 alcance regulatorio del primer piso y del descuento de facturas · D2 reglas de canal con aliados · D3 apetito de riesgo (recurso, concentración por pagador) · D4 modelos de IA y residencia de datos · D5 gobierno de modelos y dueño de los evals · D6 tamaño del equipo de analistas y atribuciones.

Anexos: prototipo funcional (repositorio, *docker compose up*), arquitectura C4 y roadmap (docs/), modelo financiero reproducible (xlsx) y declaración de uso de IA. Uso de IA: asistente Claude para investigación, código, documentación y modelo; las decisiones de producto, supuestos y límites son del autor.